Цифровая обработка изображений

Лекция 9

Сегментация.

Сафонов Илья Владимирович

ilia.safonov@gmail.com

2025

Сегментация

Сегментация (segmentation) – это разделение сигнала/изображения на содержательно интерпретируемые области, где каждый отсчёт/пиксел относится к области определённого типа.

Если происходит разделение изображения на объекты переднего плана (или объекты интереса) и фон, то в качестве синонима сегментации часто используют термин бинаризация (binarization).

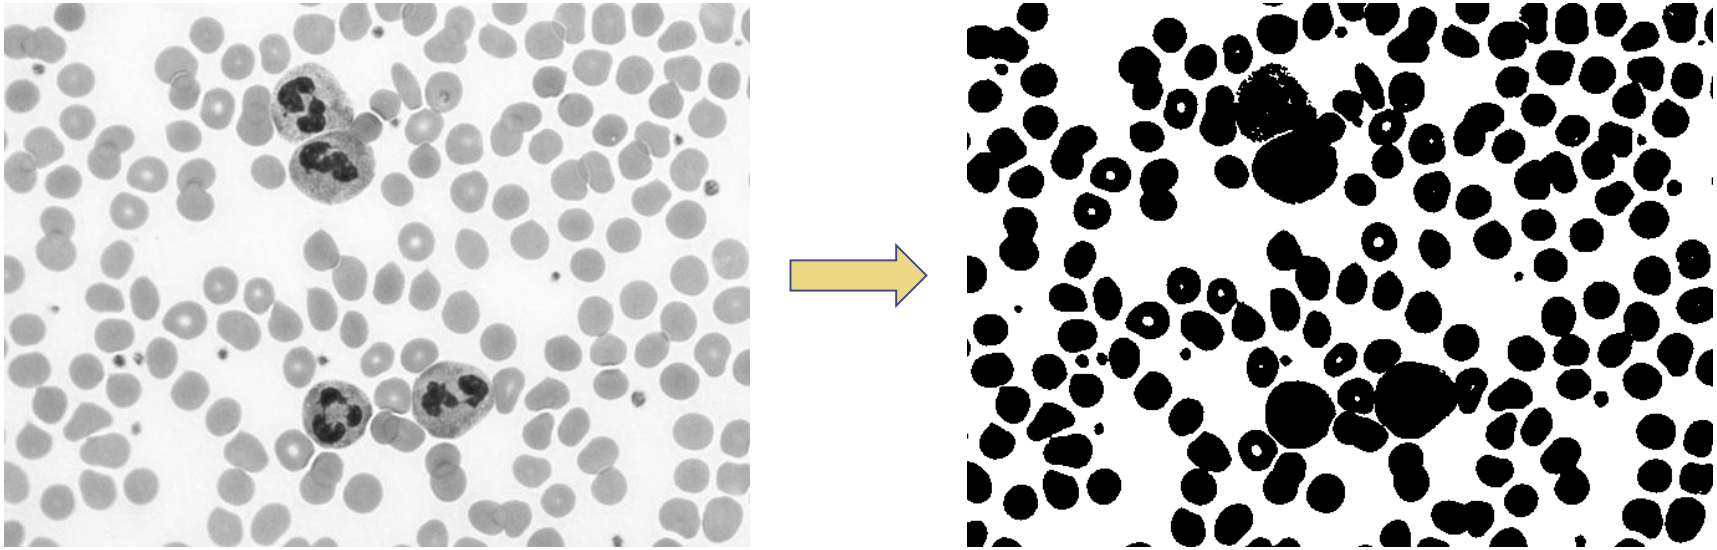

Подходы к сегментации

Сегментация, по сути, является задачей классификации пикселов изображения, поэтому для сегментации применяется множество подходов машинного обучения (*machine learning*) и распознавания образов (*pattern recognition*).

Если алгоритм сегментации создают исходя из набора образцов объектов, которые надо сегментировать, то это индуктивный подход (от частного к общему), основанный на машинном обучении. Качество сегментации определяется качеством данных для обучения.

Если алгоритм сегментации создают исходя из априорных знаний о сегментируемых объектах, то это дедуктивный подход (от общего к частному). Качество сегментации определяется качеством априорных знаний.

Типы сегментации

Различают *семантическую* (*semantic*) *сегментацию*, при которой пиксели всех объектов одного типа маркируются одинаковым образом, и *сегментацию экземпляров* (*instance*), при которой каждый объект относят к отдельному сегменту.

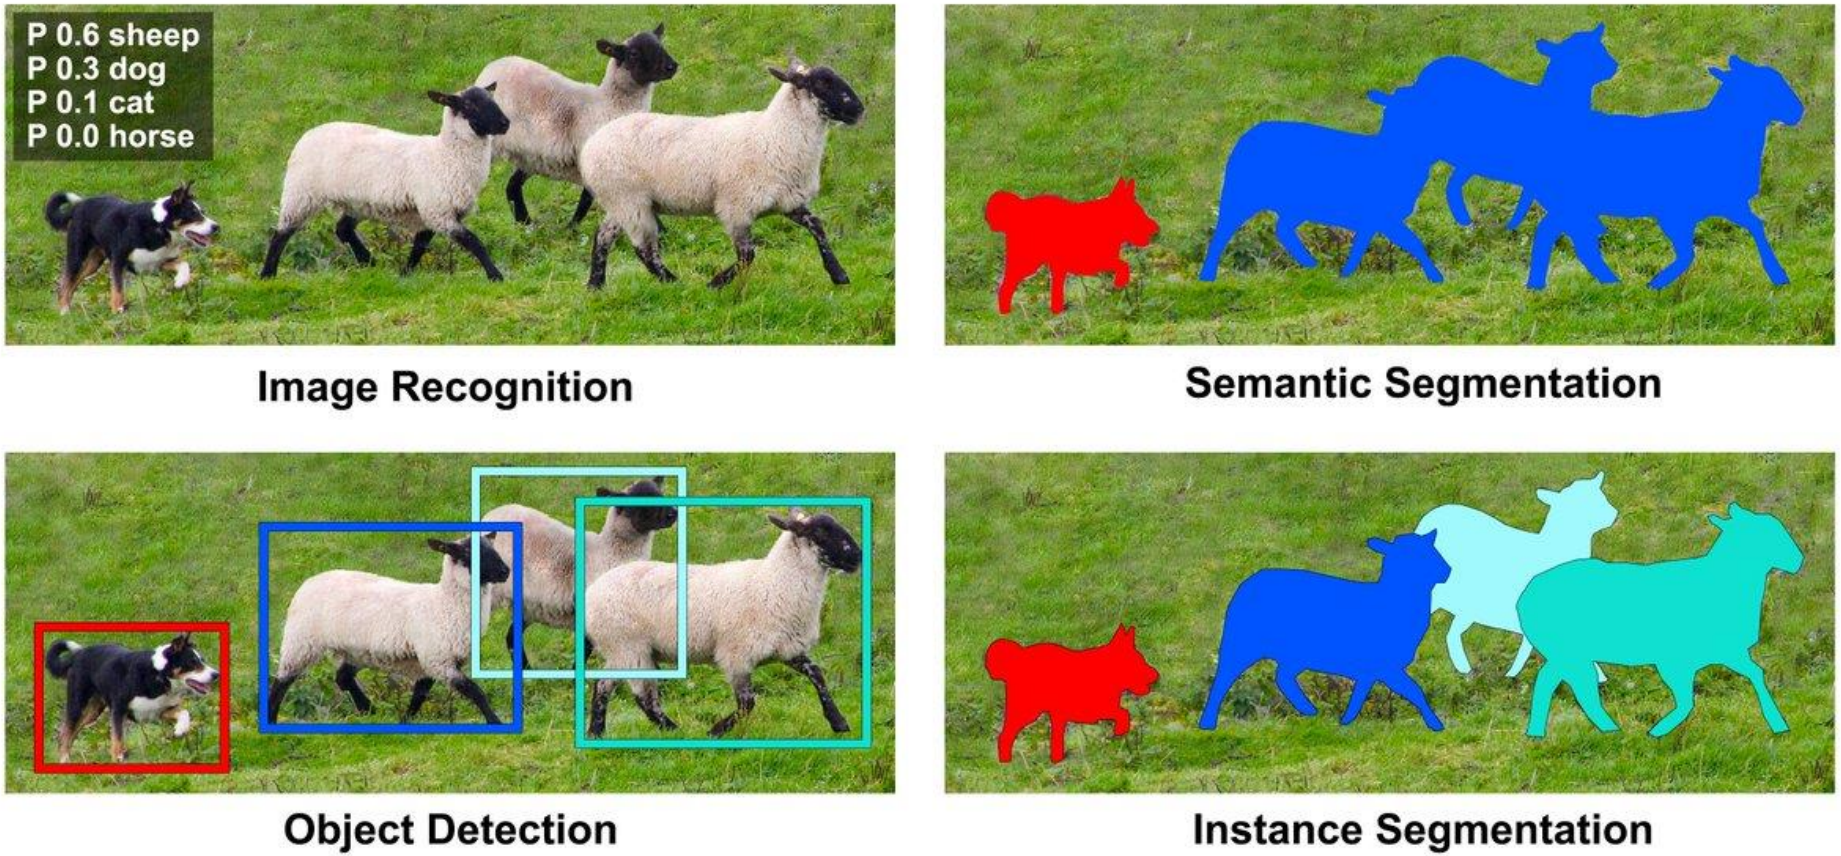

Пороговая сегментация

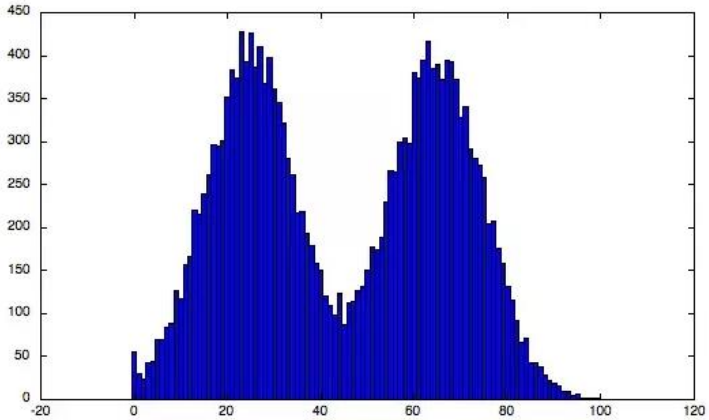

Пороговое отсечение само по себе является простейшим способом семантической сегментации, кроме того часто является одним из этапов в составных алгоритмах.

При пороговой сегментации по одному или нескольким порогам по цветовым составляющим или вычисленным по изображению атрибутам принимается решение о принадлежности пиксела к тому или иному классу.

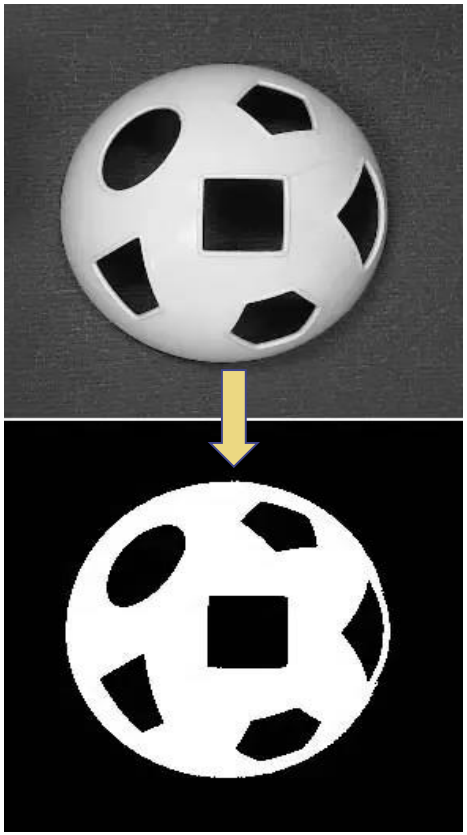

При бинаризации полутоновых изображений, как правило, хороший результат сегментации получается в случае бимодальной гистограммы изображения. Порог устанавливается посередине между пиками гистограммы, все пикселы меньше равные порогу помещают в 0-й класс, все пикселы больше порога – в 1-й класс. Для автоматического нахождения положения порога между пиками существует несколько алгоритмов.

Нахождение порога алгоритмом Оцу

В алгоритме Оцу (Otsu) порог t ищется полным перебором с целью найти минимум внутриклассовой дисперсии:

$$\sigma_w^2(t) = \omega_0(t)\sigma_0^2(t) + \omega_1(t)\sigma_1^2(t)$$

$$\omega_0(t) = \sum_{i=0}^{t-1} p(i) \qquad \omega_1(t) = \sum_{i=t}^{L-1} p(i)$$

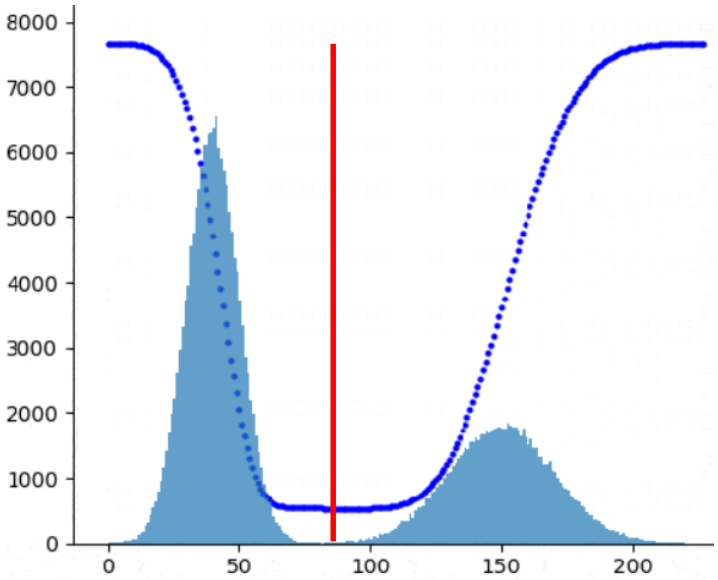

На бимодальной гистограмме показан порог в месте минимума внутриклассовой дисперсии

Для двух классов минимизация внутриклассовой дисперсии эквивалентна максимизации межклассовой дисперсии:

$$\sigma_b^2(t) = \sigma^2 - \sigma_w^2(t) = \omega_0(\mu_0 - \mu_T)^2 + \omega_1(\mu_1 - \mu_T)^2$$
$$= \omega_0(t)\omega_1(t)[\mu_0(t) - \mu_1(t)]^2$$

$$\mu_0(t) = \frac{\sum_{i=0}^{t-1} ip(i)}{\omega_0(t)} \qquad \mu_1(t) = \frac{\sum_{i=t}^{L-1} ip(i)}{\omega_1(t)} \qquad \mu_T = \sum_{i=0}^{L-1} ip(i)$$

Соседство и связность (1)

Для ряда задач на практике часто сначала выполняют семантическую сегментацию, а затем каждую *связную (connected) область* считают отдельным экземпляром, выполняя таким образом instance сегментацию.

В связной области между любыми двумя пикселами существует непрерывный путь, состоящий из пикселов, также принадлежащих данной области и являющихся при этом "соседями" в смысле заданного отношения соседства.

Для 2D изображений с пикселями в декартовой системе координат различают два типа соседства (четырёх-соседство и восьми-соседство) и, соответственно, различают четырёх-связность и восьми-связность.

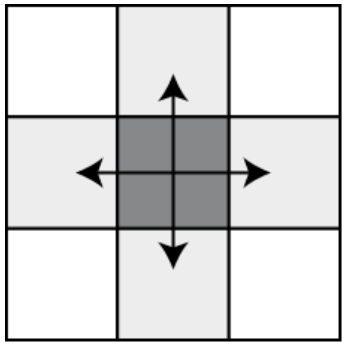

4-х соседи

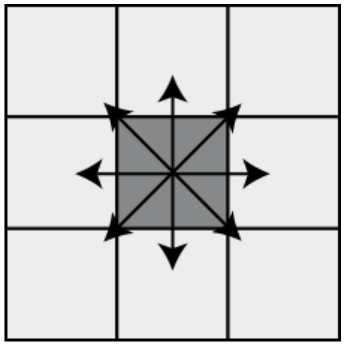

8-и соседи

Соседство и связность (1)

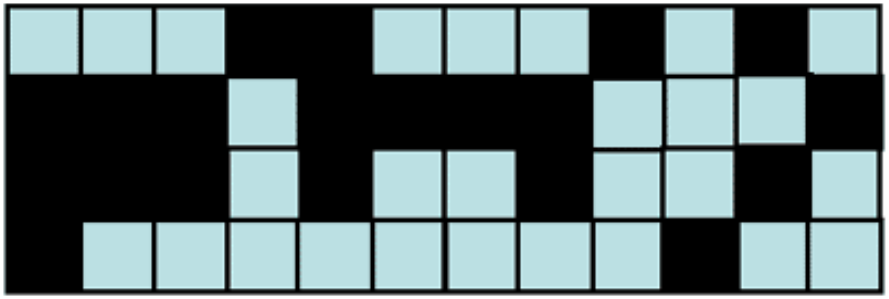

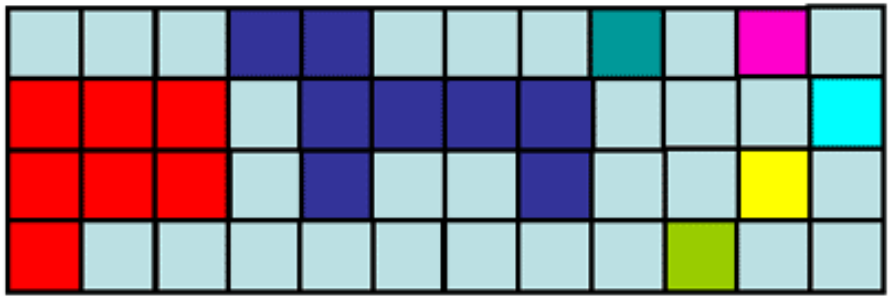

Для 4-х связности на данном изображении 7 областей

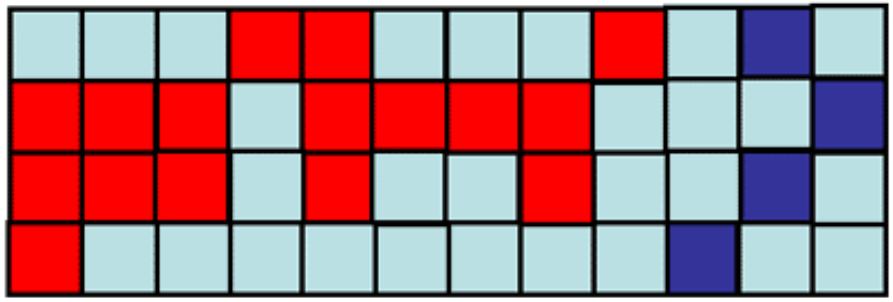

Для 8-и связности на данном изображении 2 области

Разметка (маркировка) областей

Для нахождения на бинарном изображении связных областей, относящихся к объектам интереса, используют алгоритмы разметки или маркировки (*connected component labeling*, *CCL*). Существует несколько способов разметки.

Один из способов основан на применении алгоритмов заливки области (FloodFill) с затравкой (*seed*), широко известных в компьютерной графике. Такой способ также упоминают как *one component at time*. FloodFill алгоритмы предназначены для закраски связных областей определённого цвета или ограниченных пикселами заданного цвета. Результат работы различаются в зависимости от типа связности.

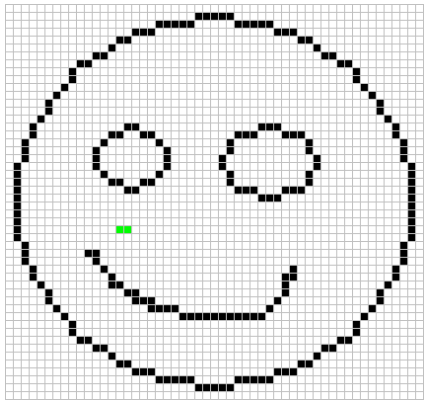

Разметка выполняется следующим образом:

- по изображению делается проход и проверяется каждый пиксел;
- если текущий пиксел не фон и не был перекрашен, то этот пиксел считается затравкой и запускается для данной области алгоритм FloodFill, который “перекрашивает” область новой меткой (*label*).

Построчный алгоритм заливки

1. При инициализации алгоритма в стек помещаются координаты затравочного пиксела, работа завершается при опустошении стека.
2. Координаты извлекаются из стека и текущая строка заполняется влево и вправо до тех пор, пока не будет найдена граница интервала.
3. В переменных X_{left} и X_{right} запоминаются значения x координаты крайних левого и правого пикселов интервала.
4. В диапазоне $X_{left} <= x <= X_{right}$ (для 4-х связного алгоритма) или в диапазоне $X_{left} - 1 <= x <= X_{right} + 1$ (для 8-и связного) проверяются строки, расположенные непосредственно над и под текущей строкой. Определяется, есть ли на них еще незаполненные пикселы. Если такие пикселы есть, то в каждом интервале крайний левый пиксел помещается в стек.

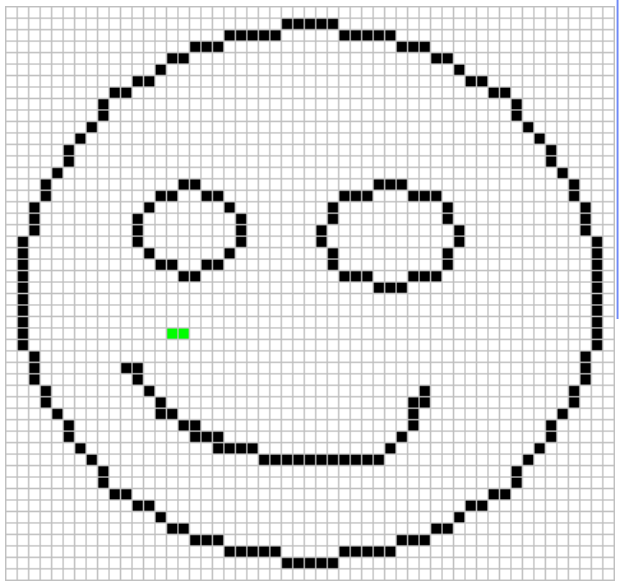

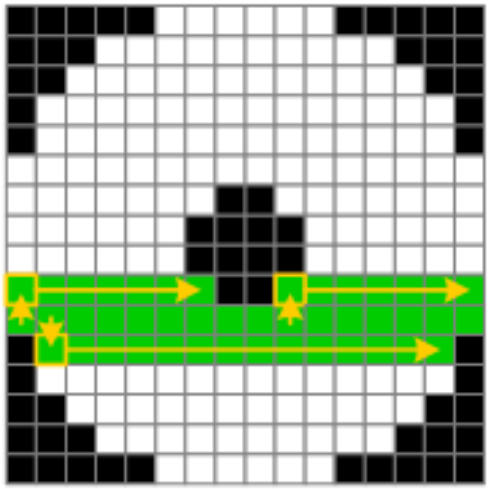

Двухпроходный алгоритм разметки

Существует ряд модификаций алгоритма разметки, который в литературе упоминается как двухпроходной (*two pass*).

Бинарное изображение сканируется слева направо и сверху вниз. Если текущий пиксел (обозначен цветом) относится к объектам интереса, то проверяются уже просмотренные пиксели (обозначены как белые квадраты с точками):

1. Если просмотренные пиксели не относятся к объектам интереса, то новая метка присваивается текущему пикселю.
2. Если просмотренные размеченные пиксели, имеют одинаковую метку, то текущему пикселю присваивается эта метка.
3. Если просмотренные размеченные пиксели, имеют разные метки, то текущему пикселю присваивается любая из меток (обычно, имеющая наименьшее значение) и все эти метки запоминаются как эквивалентные.

При втором проходе эквивалентные метки заменяются на одинаковые.

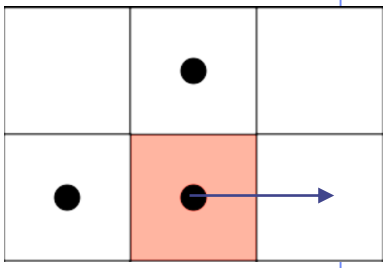

4-х связность

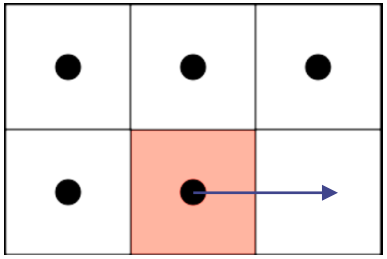

8-и связность

Двухпроходный алгоритм разметки: пример

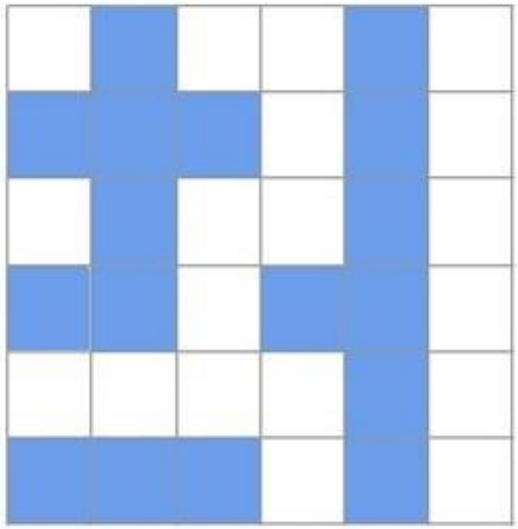

	1			2	
3	3	3		2	
	3			2	
4	4		5	5	
				5	
6	6	6		5	

	1			2	
1	1	1		2	
	1			2	
1	1		2	2	
				2	
6	6	6		2	

4-connected

	2	
1	•	

- {1,3,4}
- {2,5}

таблица эквивалентных меток

На практике часто эквивалентные метки переназначают в изображении в первом проходе, а таблица эквивалентности не создаётся.

Если выполняется разметка *in place* (т.е. в одном и том же массиве), то для двухпроходного алгоритма значения меток получаются не подряд.

Алгоритм разбиения/слияния (1)

Вводится два критерия *однородности* (*homogeneity*) области: для разбиения (разделения, split) и слияния (объединения, merge).

В качестве критериев однородности обычно выступают пороговые ограничения для дисперсии, или разность между максимальным и минимальным значениями, или разность между какими-либо другими статистиками, например, значениями перцентилей.

Если прямоугольная область неоднородна, то она разделяется на 4 равные подобласти. Процесс продолжается до тех пор, пока есть неоднородные области для разделения.

Затем попарно соседние области проверяются на возможность объединения: если для объединённой области будет выполняться критерий однородности, то области объединяют. Процесс продолжается пока есть области для объединения.

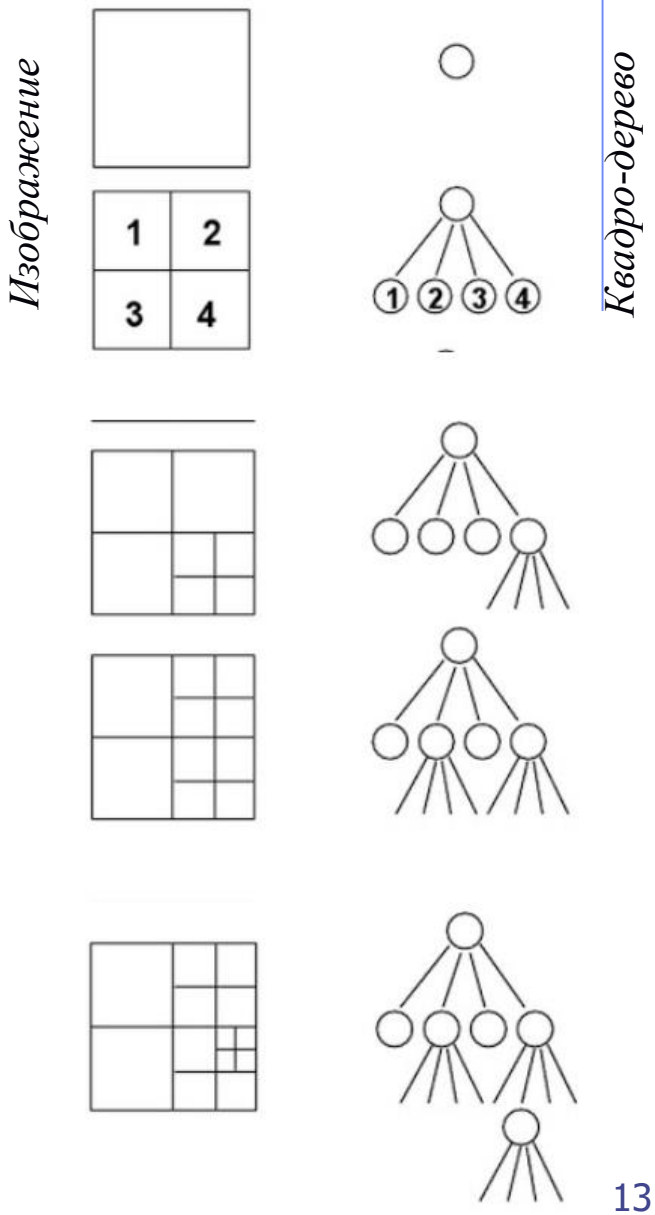

Алгоритм разбиения/слияния (2)

1	1	1	1	1	1	1	2
1	1	1	1	1	1	1	0
3	1	4	9	9	8	1	0
1	1	8	8	8	4	1	0
1	1	6	6	6	3	1	0
1	1	5	6	6	3	1	0
1	1	5	6	6	2	1	0
1	1	1	1	1	1	0	0

Исходное изображение

1	1	1	1	1	1	1	2
1	1	1	1	1	1	1	0
3	1	4	9	9	8	1	0
1	1	8	8	8	4	1	0
1	1	6	6	6	3	1	0
1	1	5	6	6	3	1	0
1	1	5	6	6	2	1	0
1	1	1	1	1	1	0	0

Первое разбиение

1	1	1	1	1	1	1	2
1	1	1	1	1	1	1	0
3	1	4	9	9	8	1	0
1	1	8	8	8	4	1	0
1	1	6	6	6	3	1	0
1	1	5	6	6	3	1	0
1	1	5	6	6	2	1	0
1	1	1	1	1	1	0	0

Второе разбиение

Критерий разбиения:

max(R) – min(R) > 1

Критерий слияния:

max(R) – min(R) <= 1

1	1	1	1	1	1	1	2
1	1	1	1	1	1	1	0
3	1	4	9	9	8	1	0
1	1	8	8	8	4	1	0
1	1	6	6	6	3	1	0
1	1	5	6	6	3	1	0
1	1	5	6	6	2	1	0
1	1	1	1	1	1	0	0

Третье разбиение

1	1	1	1	1	1	1	2
1	1	1	1	1	1	1	0
3	1	4	9	9	8	1	0
1	1	8	8	8	4	1	0
1	1	6	6	6	3	1	0
1	1	5	6	6	3	1	0
1	1	5	6	6	2	1	0
1	1	1	1	1	1	0	0

Слияние

Алгоритм разбиения/слияния (3)

Исходное изображение

Карта признаков

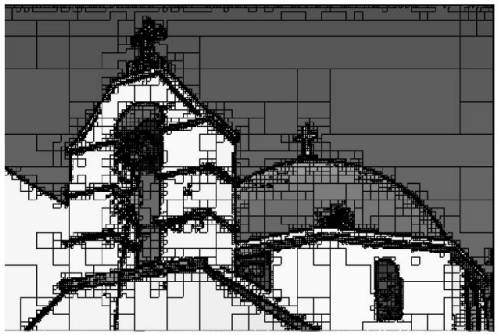

Разбиение

Слияние

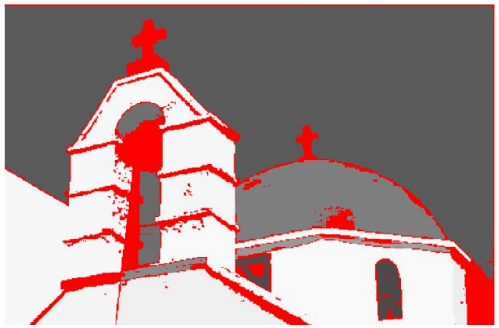

Подавление малых областей

Результат

Недостатки:

- результат зависит от порядка выбора областей для слияния
- сложно подобрать адекватные критерии однородности, чтобы избежать чрезмерной сегментации (*oversegmentation*), которая для данного алгоритма, как правило, выражается в образовании большого количества маленьких областей, или недостаточной сегментации (*undersegmentation*), когда в общие сегменты объединяются разные по смыслу области

Разбиение на суперпиксели

Развитием идеи алгоритма разбиения/слияния является разбиение изображения на суперпиксели (*superpixel*) – области произвольной формы, для которых выполняются критерии однородности и компактности. Существует несколько способов разбиения на суперпиксели.

Для сегментации требуется объединение похожих (вводится критерий схожести, *similarity*) суперпикселов с помощью иерархической агломерации по графу смежности (*hierarchical agglomeration by Region Adjacency Graph (RAG)*).

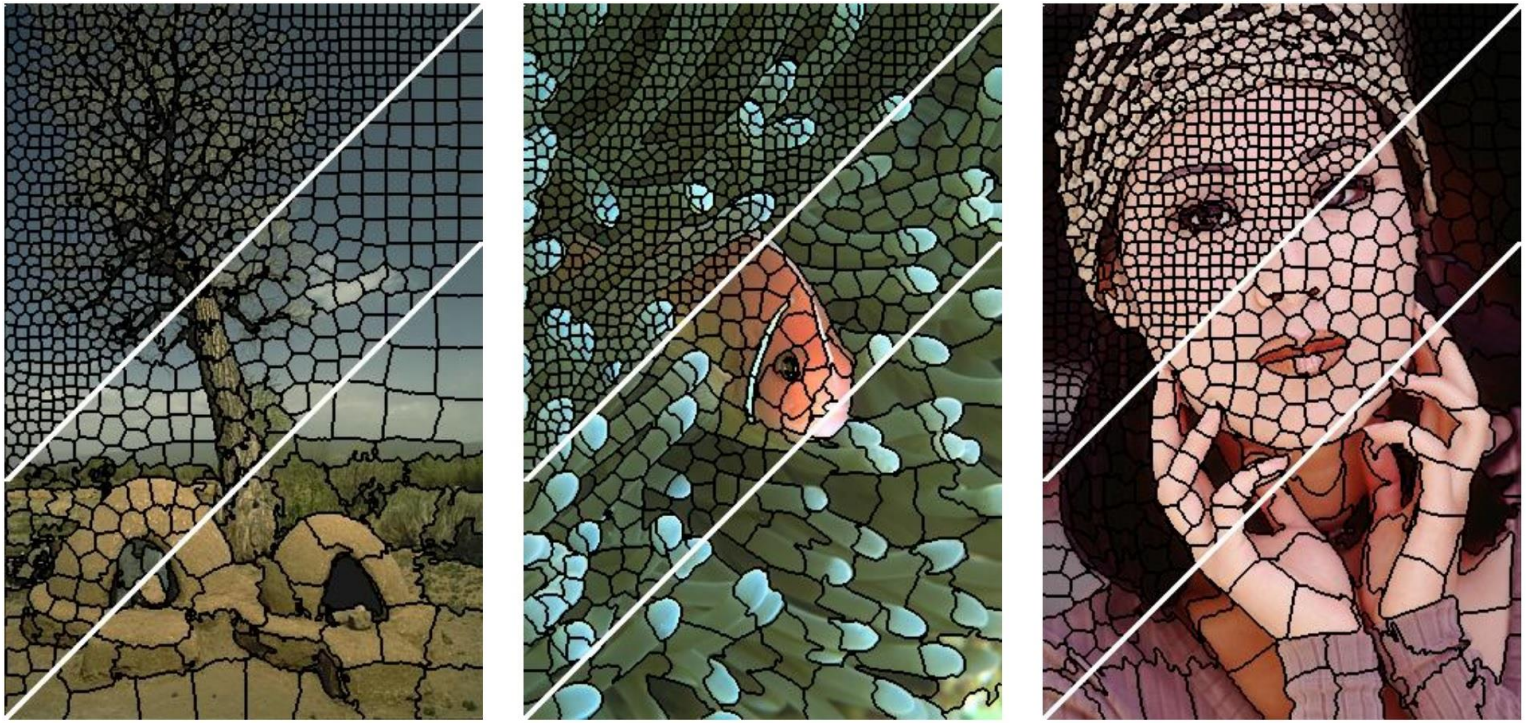

Разбиение на суперпиксели в зависимости от критерия компактности

Водораздел (1)

В алгоритме *водораздела* (*watershed*) из изображения формируют карту, которая рассматривается как рельеф местности. В местах локальных минимумов образуются водосборные бассейны. Бассейны начинают заполняться. В пикселах, где встречаются воды из соседних бассейнов строится граница между сегментами.

Поскольку локальных минимумов может быть много, то чтобы избежать чрезмерной сегментации часто выбирают инициирующие точки бассейнов. Такие точки/области называют маркерами, а алгоритм маркерным водоразделом (*marker-controlled watershed*).

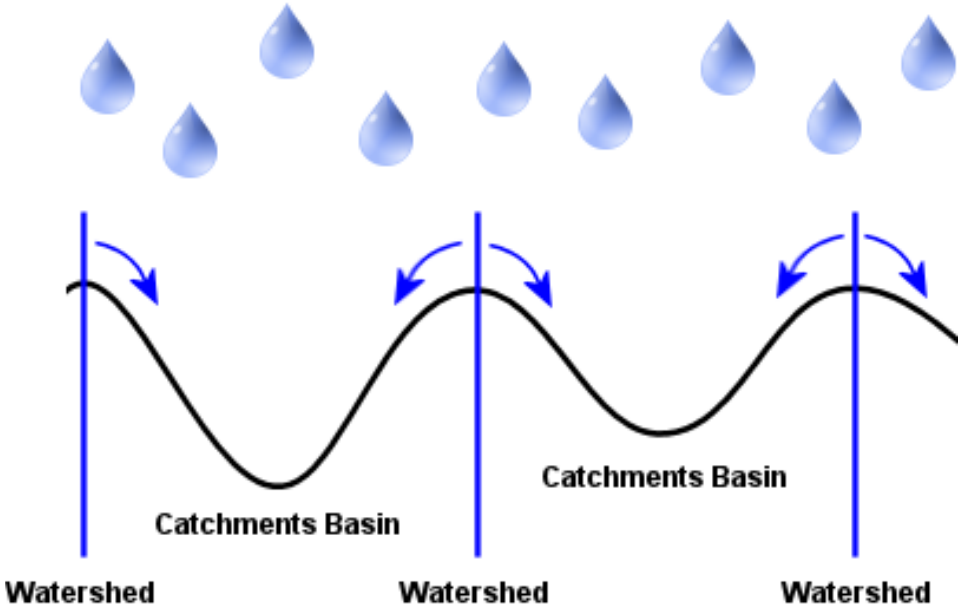

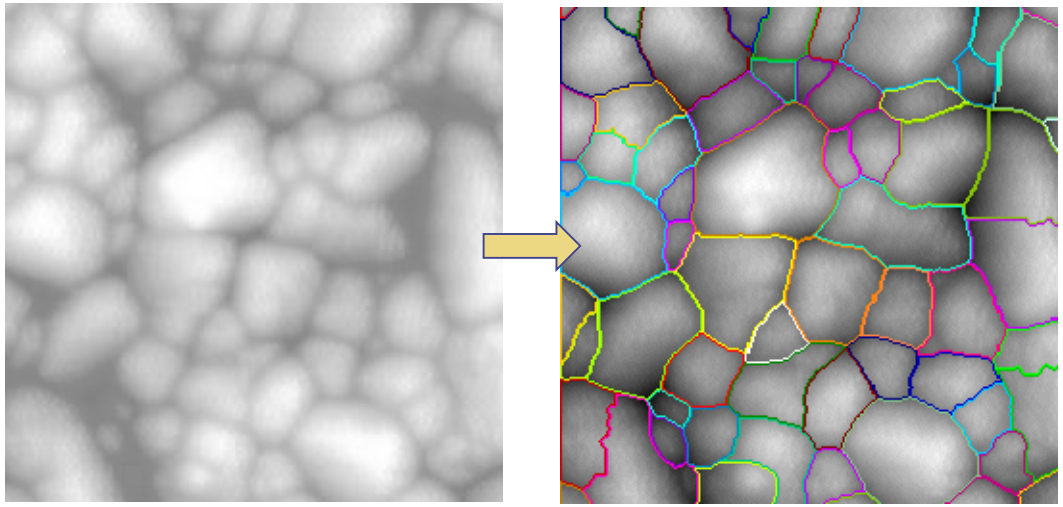

Сегментация водоразделом, где в качестве рельефа используется само изображение

Водораздел (2)

Одной из типичных задач применения алгоритма водораздела является сегментация экземпляров выпуклых частиц, которые на изображении касаются друг друга, поэтому после семантической сегментации на изображении частицы “слипаются”.

Для построения рельефа к результату бинаризации применяют “*преобразование расстояние*” (*distance transform*), при котором каждый пиксел равен евклидову расстоянию до ближайшего пикселя фона.

Получающиеся линии водораздела разделяют “слипшиеся” частицы.

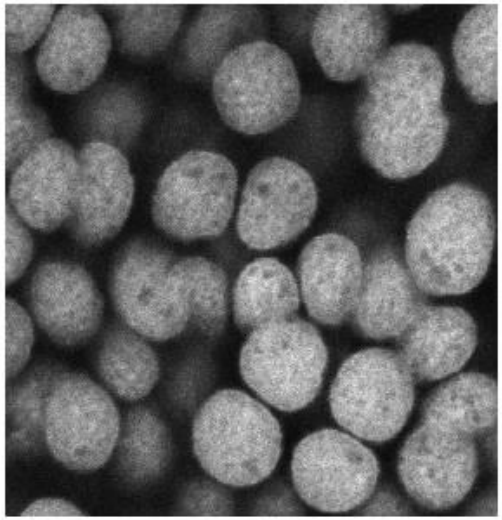

Исходное изображение

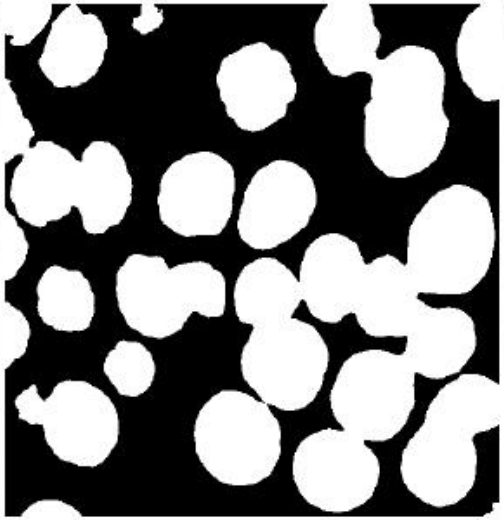

Бинаризация

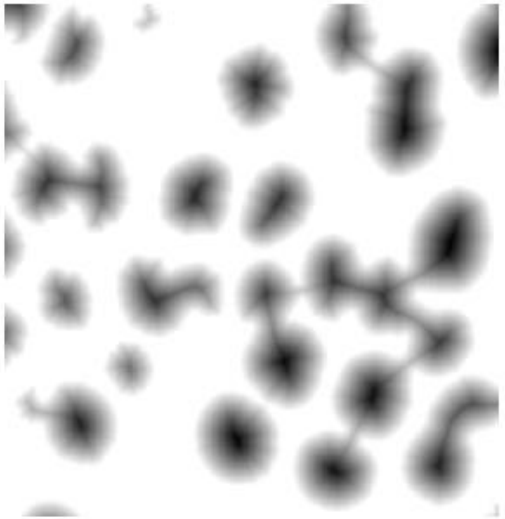

Inverse distance transform

Сегментация

Сегментация как задача машинного обучения

Сегментация может осуществляться методами машинного обучения.

В случае обучения без учителя (*unsupervised learning*) используют алгоритмы кластеризации, например, k-means, mean-shift. Кластеризацию производят в пространстве признаков, каждый из которых характеризует локальную область изображения, например, среднее значение и дисперсия интенсивности в области.

В случае обучения с учителем (*supervised learning*) используют алгоритмы классификации, например, kNN, SVM, Random Forest или нейронные сети. Для обучения необходимо иметь представительную размеченную выборку, которая для обучения, настройки параметров и проверки эффективности работы разбивается на обучающую, валидационную и тестовую. В случае использования классических алгоритмов машинного обучения по выборке вычисляются признаки локальных областей изображения. При использовании *глубокого обучения* (*deep learning*) в выборке хранятся сами изображения и разметка (*ground truth*). На качество сегментации определяющее значение оказывает качество и объём размеченных данных используемых при обучении.

Метод k-средних (1)

Алгоритм кластеризации k-средних (k-means) стремится минимизировать суммарное квадратичное отклонение точек кластеров от центров этих кластеров. Шаги алгоритма следующие:

1. Задаётся число кластеров k, по числу k случайным образом выбирается k положений центроид, это могут быть как точки выборки, так и произвольное позиции в используемом пространстве признаков.
2. Все точки по евклидову расстоянию до ближайшей центроиды относят к кластерам.
3. Для каждого кластера вычисляется новое положение центроиды (координаты центра масс).
4. Повторяют шаги 2 и 3 до тех пор пока для последовательных итераций не будет происходить изменение в составе кластеров.

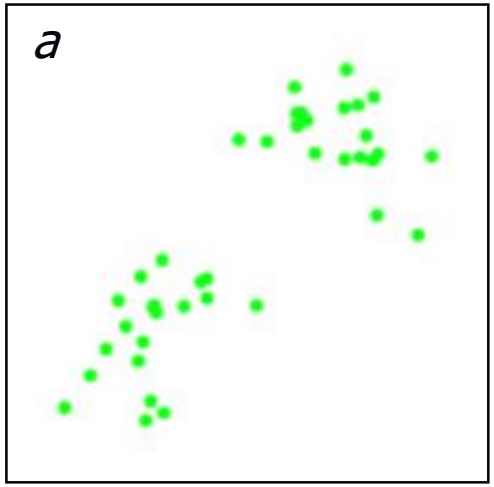

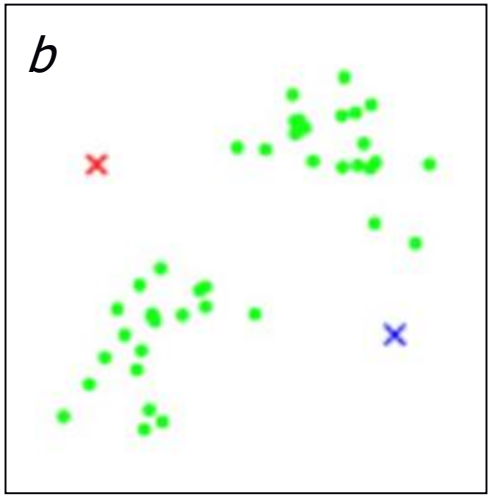

Метод k-средних (2)

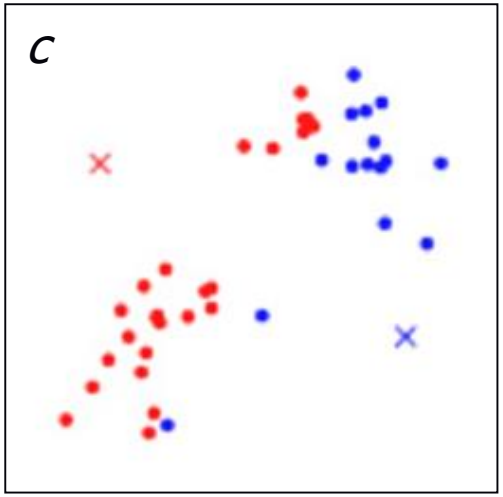

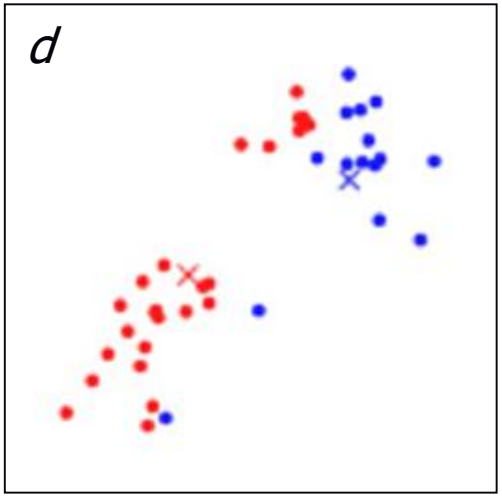

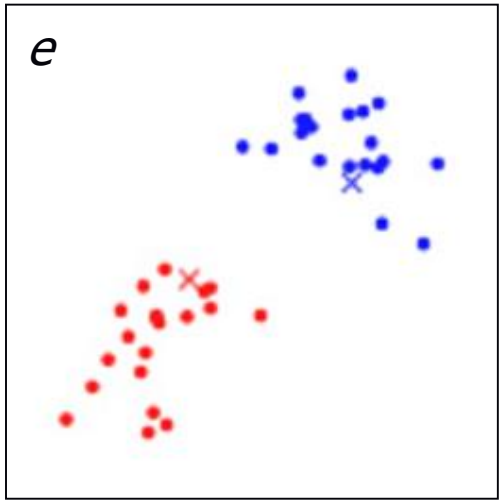

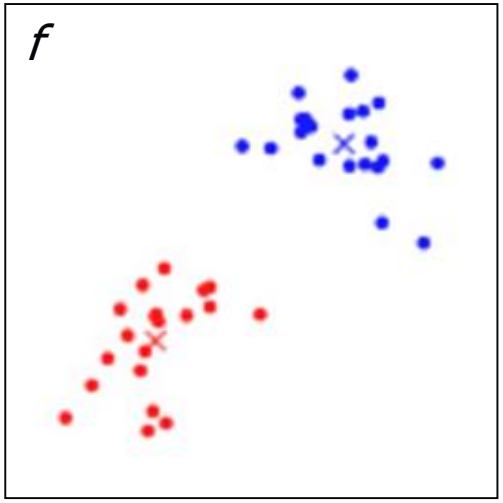

Недостатки k-means:

- не гарантируется достижение глобального минимума суммарного квадратичного отклонения, а только одного из локальных минимумов
- результат зависит от выбора исходных центров кластеров, их оптимальный выбор неизвестен
- число кластеров надо знать заранее

Метод k-средних (3)

Для автоматического выбора k существует эмпирический способ “локтя” (elbow). Он заключается в выполнении кластеризации для диапазона значений k и вычислении суммы сумм квадратов расстояний внутри кластеров (Within Cluster Sum of Squares, WCSS). Место резкого излома графика WCSS(k) полагают “оптимальным” значением k.

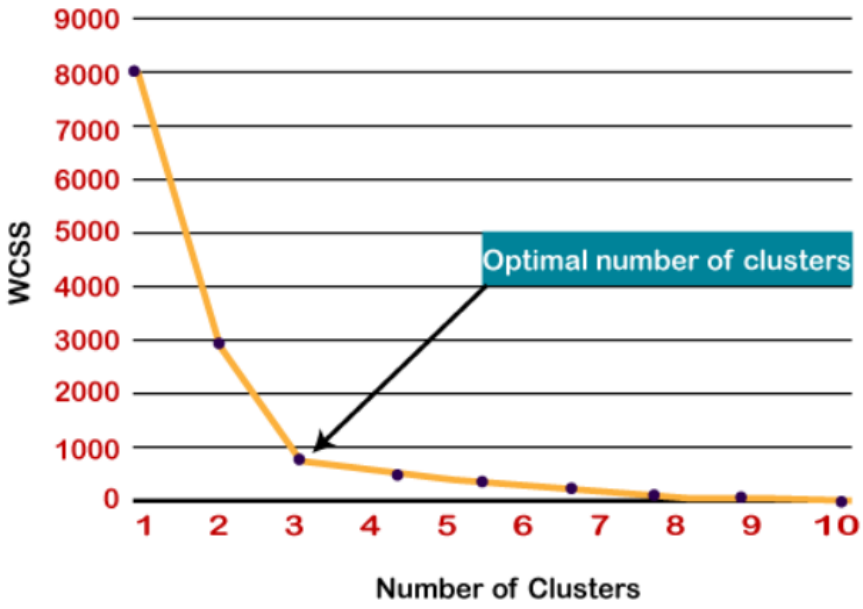

Существует множество модификаций алгоритма k-means:

- по способу задания исходного положения центроид, например, k-means++
- по способу вычисления положения “центроид”, например, использовать не арифметическое среднее, а медиану
- для каждого элемента из рассматриваемого множества рассчитывать степень его принадлежности каждому из кластеров, например, fuzzy k-means / c-means
- по способу вычисления расстояния в пространстве признаков

Сегментация с помощью классификации (1)

Рассмотрим пример сегментации с помощью классификатора, обученного с учителем. Решается задача сегментации областей текста, иллюстраций и равномерного фона на сканированных изображениях страниц журналов.

1. Создаётся выборка из нескольких сотен сканированных изображений страниц различных журналов. Изображения размечаются (аннотируются) вручную на три класса.

2. Изображение разбивается на частично-перекрывающиеся блоки *NxN* пикселов. Для каждого блока вычисляется около двух десятков признаков.

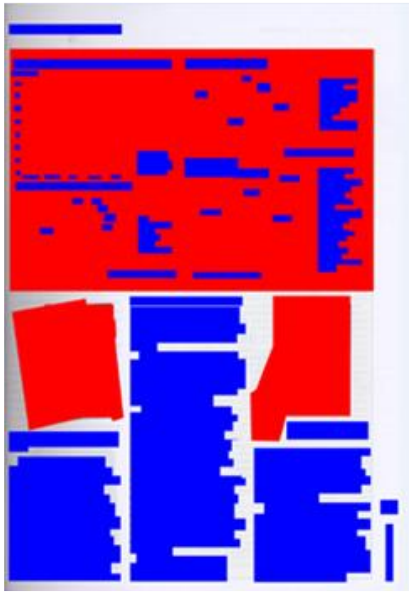

Примеры признаков для блока B_i.

Среднее значение интенсивности:

$$\overline{B_i} = \frac{\sum_{r=1}^{N}\sum_{c=1}^{N} B_i(r,c)}{N^2}$$

Среднеквадратичное отклонение:

$$\sigma_i = \sqrt{\frac{\sum_{r=1}^{N}\sum_{c=1}^{N} (\overline{B_i} - B_i(r,c))^2}{N}}$$

Сегментация с помощью классификации (2)

Среднее среди разностей средних текущего блока и 4-х его соседей:

$$dB_i = \frac{\sum_{k=1}^{4} \left| \overline{B_i} - \overline{B_k} \right|}{4}$$

Среднее расстояние до пиксела, имеющего наибольшее отличие по интенсивности от остальных:

$$F_{dist}^{i} = \frac{\sum_{r=1}^{N} \sum_{c=1}^{N} \sqrt{(c_m - c)^2 + (r_m - r)^2}}{N^2}$$

Однородность матрицы совместной встречаемости:

$$H^i = \sum_{k,m} \frac{N_d(k,m)}{1 + |k - m|}$$

Среднее среди сумм вертикальных и горизонтальных конечных разностей:

$$\overline{d_{x,y} B_i} = \frac{\sum_{r=1}^{N} \sum_{c=2}^{N-1} dB_x^i(r,c) + \sum_{r=2}^{N-1} \sum_{c=1}^{N} dB_y^i(r,c)}{2(N-2)^2}$$

$$dB_x^i(r,c) = \frac{\left| B_i(r,c+1) - B_i(r,c) \right| + \left| B_i(r,c-1) - B_i(r,c) \right|}{2}$$

$$dB_y^i(r,c) = \frac{\left| B_i(r+1,c) - B_i(r,c) \right| + \left| B_i(r-1,c) - B_i(r,c) \right|}{2}$$

Средний модуль градиента:

$$G^i = \frac{\sum_{r=2}^{N-1} \sum_{c=2}^{N-1} \nabla B_i(r,c)}{(N-2)^2}$$

$$\nabla B_i(r,c) = \sqrt{(dB_x^i(r,c))^2 + (dB_y^i(r,c))^2}$$

Сегментация с помощью классификации (3)
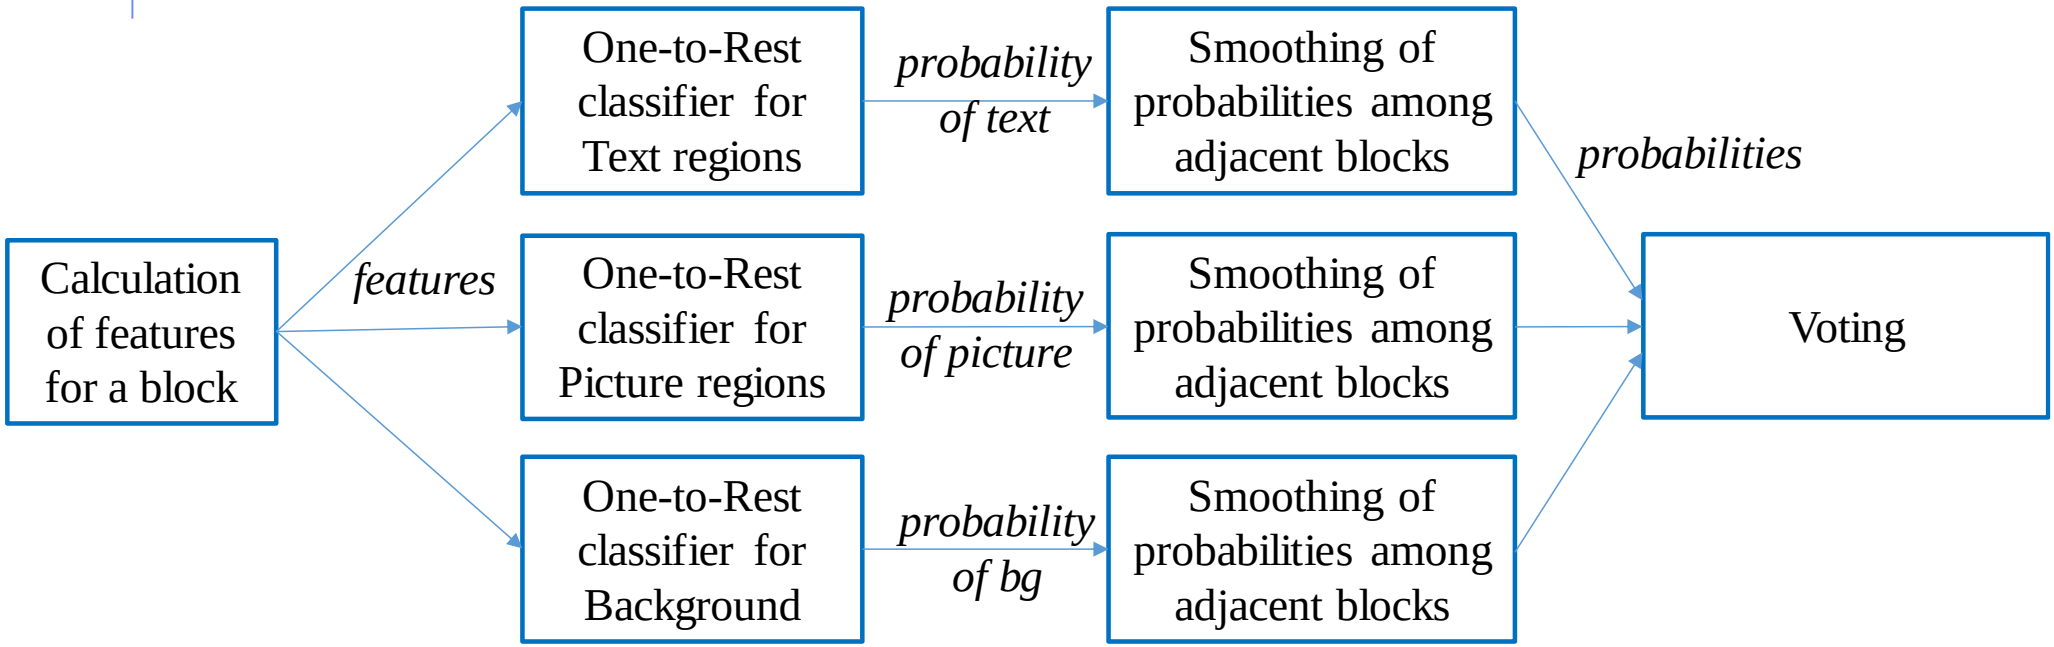
3. На обучающей выборке обучается 3 классификатора (подход “один против всех”, one-to-rest) с помощью алгоритма Случайный лес (*Random Forest*).
4. На валидационной выборке подбираются параметры классификаторов.
5. Сегментация изображений выполняется с помощью следующей схемы: